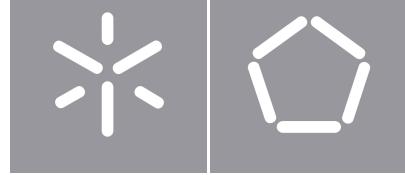


University of Minho
School of Engineering

Diogo Alexandre Correia Marques

**Realistic Benchmarking of Data Deduplication
and Compression Systems**



University of Minho
School of Engineering

Diogo Alexandre Correia Marques

**Realistic Benchmarking of Data Deduplication
and Compression Systems**

Master's Dissertation in Informatics Engineering

Dissertation supervised by
João Tiago Medeiros Paulo

Abstract

Write abstract here (in English)

Keywords keywords, here, comma, separated

Resumo

A deduplicação de dados corresponde a uma técnica para identificar e remover conteúdos duplicados em sistemas de armazenamento, contribuindo assim para uma melhor utilização do espaço disponível e consequente redução de custos. De facto, os sistemas modernos combinam ainda técnicas de compressão para extrair maior densidade dos dados e armazenar somente o exatamente necessário.

Ao suportarem várias técnicas de manipulação de dados, a avaliação destes sistemas torna-se cada vez mais complexa, dado que as workloads necessitam de responder a uma série de critérios que validem a deduplicação e compressão em simultâneo, sem esquecer que as características comuns entre sistemas devem continuar no alvo da avaliação, em particular a localidade espacial e temporal dos acessos.

No entanto, os benchmarks disponíveis à comunidade ([fio](#), [vdbench](#)) apenas permitem uma manipulação parcial dos níveis de entropia e deduplicação. Sem mencionar que a simulação de traces é demasiado simplista e torna-se impraticável em sistemas modernos por estes serem demasiado rápidos a concluir o trace e não existir uma forma trivial de extender o mesmo e preservar as suas características.

Além disso, no sentido de extrair o máximo de performance, alguns sistemas disponibilizam unicamente interfaces de I/O baixo nível, tal como [SPDK](#), o torna ainda mais complicada a execução de workloads, pois os benchmarks anteriormente referidos não suportam diretamente tais protocolos para comunicação com o disco.

Posto isto, esta dissertação tem por objetivo desenvolver um benchmark para sistemas de armazenamento, sendo este capaz de suportar diversas interfaces de I/O, bem como a geração de workloads realistas que permitam a recolha de métricas relevantes para a avaliação do sistema, permitindo assim a identificação de gargalos de desempenho e impactos associados às características do sistema de armazenamento.

Palavras-chave sistema de armazenamento, interface de I/O, deduplicação, compressão, workload realista

Contents

| | | |
|-----|--|---|
| 1 | Introduction | 2 |
| 1.1 | Problem Statement and Objectives | 2 |
| 1.2 | Contributions | 2 |
| 1.3 | Document Structure | 2 |

List of Figures

List of Tables

Acronyms

FIO Flexible I/O Tester.

SPDK Storage Performance Development Kit.

vbdev virtual block device.

Chapter 1

Introduction

1.1 Problem Statement and Objectives

1.2 Contributions

1.3 Document Structure

